

Akustická prediktívna údržba priemyselných zariadení pomocou okrajového strojového učenia a IoT*

Gabriela Tov, Pavol Ustimenko, Ján Vargovčík

Slovenská technická univerzita v Bratislave
Fakulta informatiky a informačných technológií
xpriezvisko@stuba.sk

30. september 2026

Abstrakt

Tento dokument predstavuje spresnenie zamerania semestrálneho projektu v rámci výzvy pre aplikovaný výskum. Projekt **SOUND-EDGE** sa zaoberá výskumom softvérovej architektúry a optimalizáciou modelov okrajového strojového učenia (TinyML) pre prediktívnu údržbu rotujúcich strojov v Priemysle 4.0. Dokument definuje oficiálny slovenský a anglický názov projektu (VV-A1-03), akronym (VV-A1-04) a podrobnú anotáciu (VV-A1-09) vrátane teoretického opodstatnenia a citácie z karentovanej literatúry.

1 Spresnenie zamerania projektu (Formulár APVV VV-A1)

Na základe požiadaviek výzvy pre aplikovaný výskum uvádzame spresnenie troch kľúčových položiek formulára žiadosti:

VV-A1-03: Názov projektu / Project Title

- **Slovenský názov:** Akustická prediktívna údržba priemyselných zariadení pomocou okrajového strojového učenia a IoT
- **Anglický názov:** Acoustic Predictive Maintenance of Industrial Equipment Using Edge Machine Learning and IoT

VV-A1-04: Akronym projektu

- **Akronym:** SOUND-EDGE

VV-A1-09: Anotácia projektu

Projekt SOUND-EDGE sa zameriava na výskum a vývoj inovatívneho systému prediktívnej údržby pre rotujúce stroje (motory, ložiská) v prostredí Priemyslu 4.0. Tradičné prístupy vyžadujú odosielanie veľkého množstva surových senzorových dát (napríklad vibrácií a akustických signálov) do cloudových úložísk. Tento prístup spôsobuje vysokú latenciu, enormnú spotrebu sieťového pásma a potenciálne bezpečnostné riziká. Komerčné riešenia sú navyše pre mnohé malé a stredné podniky finančne nákladné.

Tento projekt rieši spomenuté problémy využitím technológie TinyML (okrajové strojové učenie – Edge AI). Hlavným cieľom je navrhnúť architektúru a optimalizované softvérové modely hlbokých neurónových sietí, ktoré sú prispôsobené pre analýzu akustických a vibračných

*Semestrálny projekt v predmete Metódy inžinierskej práce, ak. rok 2026/2027, vedenie: Ing. Ivan Kapustík

signálov priamo v prostredí nízkonákladových, energeticky obmedzených IoT zariadení. Ako uvádzajú odborné štúdie v oblasti priemyselnej diagnostiky, spracovanie dát priamo na zariadení výrazne znižuje spotrebu energie spojenú s bezdrôtovým prenosom dát a zvyšuje celkovú odozvu a súkromie systému [1]. Cloudové služby budú v navrhovanej architektúre využité výhradne na agregáciu sumárnych štatistík anomálií, čím sa minimalizuje objem prenášaných dát.

Hlavným výstupom projektu bude návrh softvérovej architektúry a simulačný model TinyML algoritmu, ktorý bude laboratórne otestovaný a vyhodnotený na dostupných benchmarkových priemyselných datasetoch (napr. databázy porúch ložísk NASA a CWRU). Výskum zabezpečí posun z teoretického konceptu do fázy softvérovo overeného riešenia (posun z TRL 3 na TRL 4). Navrhnutá metodika a simulačné experimenty preukážu schopnosť systému včasne detegovať mikroskopické poruchy, čo podnikom poskytne overený základ pre znižovanie nákladov na údržbu a predlžovanie životnosti výrobných zariadení.

2 Vedecké opodstatnenie a rešeršný základ

Projekt stavia na nedávnych poznatkoch v oblasti spájania IoT architektúr a ľahkých modelov strojového učenia. Kľúčové tvrdenie o energetickej úspornosti a znížení latencie pri spracovaní dát priamo na okraji siete (Edge AI) je podporované výskumom Abati et al. [1], kde autori preukázali, že prenos nespracovaných akustických signálov je rádovo energeticky náročnejší než lokálna inferencia na mikrokontroléri.

Pre overenie vlastností navrhovaného algoritmickeho riešenia budú v rámci simulačných experimentov použité štandardné benchmarkové súbory dát, predovšetkým dataset NASA Bearing [2], ktorý obsahuje kontinuálne záznamy vibrácií až do štádia zlyhania ložiska.

Literatúra

- [1] R. Abati, M. Gai, and G. Ciaramella. Application of tiny machine learning in predictive maintenance in industries. *IEEE Transactions on Industrial Informatics*, 20(4):1102–1112, 2024.
- [2] J. Lee, H. Qiu, G. Yu, and J. Lin. Bearing data set. NASA Prognostics Data Repository, NASA Ames Research Center, Moffett Field, CA, 2007.